AYUDANTÍA 03 · FAGOB 2026

Análisis descriptivo, bivariado y gráficos

Métodos Cuantitativos para la Administración Pública

Cristóbal Mejías · Facultad de Gobierno Jueves 10 de abril, 2026

Agenda de hoy

¿Qué haremos?

1. Cargar datos procesados de AY-2
2. Tablas de frecuencia con `dplyr` + `kableExtra`
3. Estadísticos descriptivos por grupo
4. Alternativas rápidas (`janitor`, `sjmisc`, `stargazer`)
5. Gráficos con `ggplot2`
6. Práctica autónoma

Duración: 90 minutos

Al final de la sesión: Sabrás generar tablas formateadas y gráficos listos para reportar — usando directamente la base procesada en AY-2.

00

Punto de partida

¿Qué hicimos en AY-2?

- Seleccionamos y renombramos variables con `select()`
- Recodificamos y convertimos a `factor` con `mutate()` + `recode()`
- Tratamos los valores especiales (-88, -99) como `NA`
- Creamos tramos con `case_when()` e `if_else()`
- Guardamos la base procesada con `saveRDS()`

Hoy retomamos desde ahí. Cargamos `casen_proc.rds` y aprendemos a **describir, cruzar y visualizar** sus variables.

Paquetes de hoy

```r
pacman::p_load(
  tidyverse,    # colección de paquetes para manipulación de datos
  dplyr,        # para manipular datos (group_by, summarise ... )
  janitor,      # para tablas rápidas de frecuencia (tabyl)
  knitr,        # para renderizar y crear tablas (kable)
  kableExtra,   # para formatear tablas (kable_classic, footnote ... )
  ggplot2,      # para gráficos (barras, boxplot, dispersión)
  stargazer,    # para estadísticos descriptivos en formato tabla
  sjmisc        # para tablas de frecuencia con etiquetas (frq)
)

options(scipen = 999) # desactivar notación científica
rm(list = ls())       # limpiar ambiente de trabajo
```

Cargar la base procesada

```r
# Opción 1: si tienes el archivo en tu carpeta output/
casen_proc <- readRDS("output/casen_proc.rds")
```

```r
# Opción 2: directamente desde GitHub
url_casen <- "https://raw.githubusercontent.com/Cristobal-Mejias-G/Clase-2-MC-FAGOB/main/output/casen_proc.rds"
tmp <- tempfile(fileext = ".rds")
download.file(url_casen, tmp, mode = "wb")
casen_proc <- readRDS(tmp)
```

```r
# Primera mirada
glimpse(casen_proc)
names(casen_proc)
```

`mode = "wb"` es clave para archivos binarios como `.rds`. Sin él, el archivo se descarga corrupto.

01

Tablas de frecuencia

La lógica de las tablas en R

Para generar una tabla bien presentada necesitamos **dos pasos**:

Paso	Herramienta	¿Para qué?
1. Procesar	`dplyr`	Calcular frecuencias, medias, porcentajes...
2. Formatear	`kableExtra`	Agregar estilo, título y nota al pie

El objeto intermedio (ej. `tab_pobreza`) **separa el procesamiento del formato**. Esto permite reutilizar los datos y mantener el código más limpio.

Paso 1: procesar con `dplyr`

```
tab_pobreza <- casen_proc %>%
  dplyr::group_by(pobreza) %>%
  dplyr::summarise(n = n()) %>%
  dplyr::mutate(prop = round(n / sum(n) * 100, 2))

tab_pobreza
```

`group_by()` agrupa los datos, `summarise()` cuenta, `mutate()` calcula el porcentaje sobre el total.

Paso 2: formatear con `kableExtra`

```r
tabla1 <- tab_pobreza %>%
  kableExtra::kbl(
    align     = "c",
    col.names = c("Situación de pobreza", "N", "%"),
    caption   = "Tabla 1. Distribución por situación de pobreza"
  ) %>%
  kableExtra::kable_classic(full_width = FALSE, position = "center", font_size = 14) %>%
  kableExtra::footnote(general       = "Fuente: Elaboración propia en base a CASEN 2024.",
                       general_title = "")
tabla1
```

Opciones clave de `kbl()`

- `col.names`: renombra columnas visibles en la tabla
- `caption`: título de la tabla
- `align`: alineación de celdas (`"c"`, `"l"`, `"r"`)

Alternativa rápida: `janitor::tabyl()`

```r
casen_proc %>%
  janitor::tabyl(pobreza, sexo) %>%
  kableExtra::kable(caption = "Tabla rápida: pobreza según sexo") %>%
  kableExtra::kable_styling(full_width = TRUE)
```

```r
# sjmisc::frq() — frecuencias con etiquetas tipo haven
sjmisc::frq(casen_proc$pobreza)
sjmisc::frq(casen_proc$sexo)
```

`tabyl()` y `frq()` son útiles para **exploración rápida**. Para el reporte final conviene el pipeline `dplyr` + `kableExtra`, que da más control sobre el formato.

02

Estadísticos descriptivos por grupo

El mismo patrón: procesar → formatear

Para variables **numéricas** cruzadas con una **categórica**, ampliamos el `summarise()`:

```
tab_ingreso <- casen_proc %>%
  dplyr::group_by(sexo) %>%
  dplyr::summarise(
    n       = n(),
    min     = min(ingreso, na.rm = TRUE),
    max     = max(ingreso, na.rm = TRUE),
    media   = round(mean(ingreso, na.rm = TRUE), 0),
    sd      = round(sd(ingreso, na.rm = TRUE), 0),
    mediana = median(ingreso, na.rm = TRUE)
  )
```

`na.rm = TRUE` es obligatorio en variables con NA — sin él la función devuelve `NA` sin error ni advertencia.

Formatear tabla de descriptivos

```r
tabla2 <- tab_ingreso %>%
  kableExtra::kbl(
    align       = "c",
    col.names   = c("Sexo", "N", "Mínimo", "Máximo", "Media", "DS", "Mediana"),
    caption     = "Tabla 2. Ingreso laboral según sexo",
    format.args = list(big.mark = ".", decimal.mark = ",")
  ) %>%
  kableExtra::kable_classic(full_width = FALSE, position = "center", font_size = 14) %>%
  kableExtra::footnote(general       = "Fuente: Elaboración propia en base a CASEN 2024.",
                       general_title = "")
tabla2
```

`format.args = list(big.mark = ".")` agrega el punto de miles en los números (1.200.000 en vez de 1200000).

El mismo patrón con otra variable de agrupación

```r
tab_ingreso_edad <- casen_proc %>%
  dplyr::group_by(tramo_edad) %>%
  dplyr::summarise(
    n       = n(),
    media   = round(mean(ingreso, na.rm = TRUE), 0),
    sd      = round(sd(ingreso, na.rm = TRUE), 0),
    mediana = median(ingreso, na.rm = TRUE)
  )

tabla3 <- tab_ingreso_edad %>%
  kableExtra::kbl(
    align     = "c",
    col.names = c("Tramo etario", "N", "Media", "DS", "Mediana"),
    caption   = "Tabla 3. Ingreso laboral según tramo etario"
  ) %>%
  kableExtra::kable_classic(full_width = FALSE, position = "center", font_size = 14) %>%
  kableExtra::footnote(general = "Fuente: Elaboración propia en base a CASEN 2024.",
                       general_title = "")
tabla3
```

Alternativa rápida: `stargazer`

```
stargazer::stargazer(
  as.data.frame(casen_proc),
  type         = "text",
  summary.stat = c("mean", "sd", "min", "max")
)
```

`stargazer` requiere `as.data.frame()` porque no acepta tibbles directamente.

Usa `type = "text"` para la consola y `type = "html"` al trabajar en Quarto.

03

Gráficos con `ggplot2`

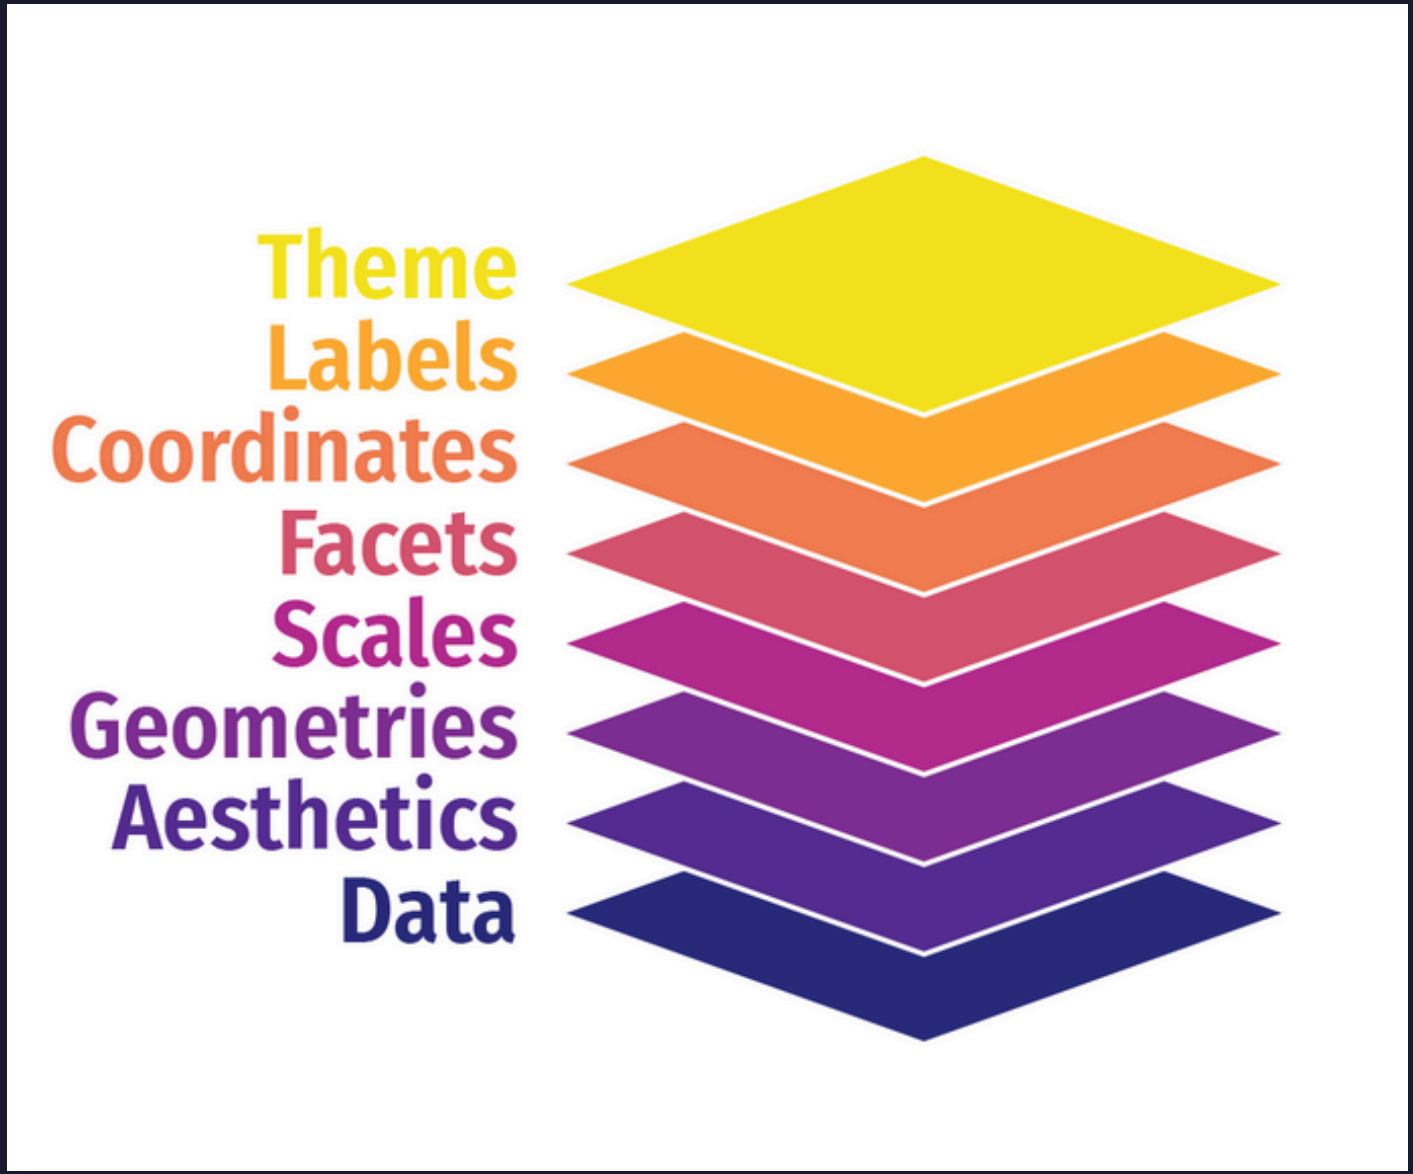
Theme
Labels
Coordinates
Facets
Scales
Geometries
Aesthetics
Data

La lógica de `ggplot2`: capas

Todo gráfico en `ggplot2` se construye sumando **capas**:

Capa	Función	¿Para qué?
1. Datos y ejes	`ggplot(data, aes( ... ))`	El lienzo
2. Geometría	`geom_*()`	La forma (barras, puntos, cajas...)
3. Etiquetas	`labs()`	Títulos, ejes, leyenda
4. Estética	`theme_*()`	El estilo visual

Las capas se encadenan con `+`. El orden importa: primero datos, luego geometría, luego ajustes.

Gráfico de barras: frecuencia de una variable

```r
ggplot(data    = casen_proc,
       mapping = aes(x = pobreza, fill = pobreza)) +  # CAPA 1: Datos y ejes
  geom_bar() +                                        # CAPA 2: Geometría
  labs(
    title   = "Distribución por situación de pobreza",
    x       = "Situación de pobreza",
    y       = "Frecuencia",
    caption = "Fuente: Elaboración propia en base a CASEN 2024."
  ) +                                                 # CAPA 3: Etiquetas
  theme_minimal() +                                   # CAPA 4: Estilo
  theme(legend.position = "none") +
  scale_fill_manual(values = c("Pobreza severa"            = "#d73027",
                               "Pobreza por ingresos"      = "#f46d43",
                               "Pobreza multidimensional"  = "#fdae61",
                               "No pobre"                  = "#4575b4"))
```

`scale_fill_manual()` permite asignar colores específicos a cada categoría.

Barras agrupadas: dos variables categóricas

```r
ggplot(casen_proc, aes(x = tramo_ingreso, fill = sexo)) +
  geom_bar(position = "dodge") +                          # separa las barras por grupo
  scale_fill_manual(values = c("darkblue", "steelblue")) +
  labs(
    title = "Distribución de tramo de ingreso según sexo",
    x     = "Tramo de ingreso",
    y     = "Frecuencia",
    fill  = "Sexo"
  ) +
  theme_light()
```

`position = "dodge"` separa las barras lado a lado.

`position = "fill"` las apila al 100% — útil para comparar proporciones.

Boxplot: distribución de variable continua por grupo

```r
casen_proc %>%
  dplyr::filter(!is.na(ingreso)) %>%              # eliminar NAs antes de graficar
  ggplot(aes(x = sexo, y = ingreso, fill = sexo)) +
  geom_boxplot(alpha = 0.7) +
  scale_y_continuous(
    labels = scales::dollar_format(prefix = "$", big.mark = ".")
  ) +
  labs(
    title = "Ingreso laboral según sexo",
    x     = "Sexo",
    y     = "Ingreso ($)"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```

`filter(!is.na( ... ))` antes del `ggplot()` evita la advertencia de filas eliminadas. `alpha` controla la transparencia (0 = transparente, 1 = sólido).

Dispersión con línea de tendencia

```r
ggplot(casen_proc %>% dplyr::filter(!is.na(ingreso)),
       aes(x = edad, y = ingreso)) +
  geom_point(alpha = 0.2) +                              # puntos semitransparentes
  geom_smooth(method = "lm", se = TRUE, color = "steelblue") + # recta + IC 95%
  labs(
    title = "Relación entre edad e ingreso laboral",
    x     = "Edad",
    y     = "Ingreso laboral ($)"
  ) +
  theme_minimal()
```

`geom_smooth(method = "lm")` agrega la recta de regresión lineal con su intervalo de confianza al 95%.

`alpha = 0.2` es útil cuando hay muchos puntos solapados — hace visible la densidad.

Mega guía

Ver R for Data Science (2e): https://r4ds.hadley.nz/data-visualize.html

Ver GGPLOT2: https://ggplot2.tidyverse.org/index.html

Podrán encontrar sobre visualización y R.

04

Práctica autónoma

Tu turno (10 min)

Con `casen_proc`, trabaja con las variables **`actividad`**, **`tramo_edad`** e **`ingreso_pc`**.

Instrucciones:

1. Genera una **tabla de frecuencias** de `actividad` con `dplyr` + `kableExtra`

   Debe incluir N, porcentaje, título y nota al pie.

2. Genera una **tabla de estadísticos descriptivos** de `ingreso_pc` por `tramo_edad`

   Reporta: n, media, sd y mediana.

3. Genera un **boxplot** de `ingreso_pc` según `actividad`.

> Usa como modelo los bloques que vimos hoy. El patrón es siempre el mismo: **procesar con `dplyr` → formatear con `kableExtra` → graficar con `ggplot2`**.

Resumen de la sesión

Tarea	Función(es)	¿Para qué?
Cargar datos	`readRDS()`	Retomar base procesada en AY-2
Frecuencias	`group_by()` + `summarise()` + `kbl()`	Tabla de distribución
Descriptivos por grupo	`group_by()` + `summarise()`	Medias, SD, mínimo, máximo
Formateo	`kable_classic()`, `footnote()`	Estilo y nota al pie
Rápida exploración	`tabyl()`, `frq()`, `stargazer()`	Vista rápida sin mucho código
Barras	`geom_bar()`	Frecuencias de variables categóricas
Boxplot	`geom_boxplot()`	Distribución de variable continua por grupo
Dispersión	`geom_point()` + `geom_smooth()`	Relación entre dos variables numéricas

¡Nos vemos en la siguiente sesión!

AY-4 · 17 de abril Documentos dinámicos con Quarto

Cristóbal Mejías · Facultad de Gobierno